

Gli agenti di intelligenza artificiale: cosa dice la ricerca

Cinque pubblicazioni recenti di BCG, Deloitte e Anthropic analizzano come funzionano gli agenti AI, quale valore creano per le organizzazioni, quali rischi portano con sé e come si valutano correttamente. Questa sintesi raccoglie i concetti principali.

● BCG — Gli agenti accelerano la prossima ondata di valore dell'IA (2025)

● Deloitte — L'IA agente si espande più velocemente dei controlli (Apr 2026)

● Anthropic — Come costruire agenti AI efficaci

● Anthropic — Ingegneria del contesto per agenti AI

● Anthropic — Come valutare le prestazioni degli agenti AI

Perché gli agenti AI cambiano le organizzazioni — e perché il controllo è in ritardo

Le ultime ricerche mostrano che siamo entrati in una nuova fase dell'intelligenza artificiale. Non si tratta più di strumenti che aiutano a prendere decisioni o a scrivere testi: gli agenti AI possono portare avanti autonomamente compiti complessi dall'inizio alla fine. Questa capacità è potente, ma crea anche rischi nuovi che molte aziende non hanno ancora affrontato: secondo Deloitte, **solo il 21% delle imprese** ha messo in piedi sistemi di controllo adeguati prima di adottare questi agenti su larga scala.

3^a

Ondata AI: analisi predittiva → contenuti generativi →
agenti autonomi

21%

delle aziende ha sistemi di controllo adeguati prima di
espandere gli agenti AI (Deloitte, survey internazionale)

79%

delle aziende espande gli agenti AI **senza controlli
sufficienti** — con rischi concreti non gestiti

FONTE: BCG 2025

Da singoli strumenti a un nuovo modo di lavorare

- › I precedenti sistemi AI analizzavano o generavano contenuti; gli agenti **pianificano, decidono ed eseguono** processi lavorativi completi in autonomia
- › Il vero guadagno non è automatizzare un compito singolo: è **ripensare come funziona il lavoro** all'interno dell'organizzazione
- › Chi ottiene risultati: identifica prima i processi ad alto impatto, costruisce un flusso di dati e di feedback, e prepara le persone a lavorare a fianco degli agenti

Il cambiamento riguarda il modello di lavoro, non solo la tecnologia

FONTE: DELOITTE APRILE 2026

I rischi crescono se non si costruisce prima il controllo

- › Agenti non supervisionati possono commettere **errori non visibili**, condividere informazioni riservate, danneggiare la relazione con i clienti o aprire vulnerabilità alla sicurezza
- › Questi problemi non sono lineari: in produzione su larga scala si **moltiplicano e si complicano**
- › Le aziende che riescono partono da casi d'uso semplici e a basso rischio, e costruiscono strutture di controllo che coinvolgono IT, area legale, compliance e i responsabili di business

Costruire i controlli prima di espandere

Come si costruisce un agente AI: semplicità prima di tutto

Anthropic — una delle principali aziende di ricerca sull'IA — ha lavorato con decine di team che costruivano agenti AI in settori diversi. La loro conclusione principale è controintuitiva: **le implementazioni di successo non usano sistemi complicati**. Usano componenti semplici, combinati in modo intelligente. Più un sistema è complesso, più è difficile da capire, correggere e migliorare. La semplicità non è una scorciatoia: è la scelta giusta.

DISTINZIONE FONDAMENTALE

Flusso guidato vs. agente autonomo

- › **Flusso guidato:** l'IA segue una sequenza di passi decisa in anticipo dagli sviluppatori — comportamento prevedibile, facile da verificare e correggere
- › **Agente autonomo:** l'IA decide da sola quali passi compiere e quali strumenti usare — più flessibile, ma anche meno prevedibile
- › Molti problemi si risolvono meglio con un **flusso semplice**: non serve sempre l'autonomia totale

PRINCIPIO GUIDA

Inizia dal più semplice, aggiungi solo se serve

- › Aggiungere complessità solo quando la versione più semplice è dimostratamente insufficiente — testare sempre il minimo prima di costruire qualcosa di elaborato
- › Più componenti = più punti di rottura, più difficile individuare dove qualcosa va storto, più lento da aggiornare
- › I team di maggior successo costruiscono pezzi piccoli e componibili, non architetture monolitiche

SCHEMA COSTRUTTIVO

Catena di passaggi

- › L'output di un passo diventa l'input del successivo — come una catena di montaggio
- › Ideale quando i passaggi sono definiti e si può verificare ogni fase
- › Semplice da testare e da correggere se qualcosa non funziona

SCHEMA COSTRUTTIVO

Smistamento intelligente

- › Un primo sistema classifica la richiesta e la indirizza al processo più adatto
- › Permette di usare strumenti semplici per richieste semplici, e strumenti più potenti solo quando servono
- › Riduce i costi e i tempi di risposta senza perdere qualità

LEZIONE PRATICA

Progettare gli strumenti pensando all'IA

- › Gli strumenti che l'agente usa devono essere progettati come se si stesse scrivendo un manuale per un collega nuovo — chiari, precisi, senza ambiguità
- › Anthropic ha migliorato più i propri strumenti che le istruzioni all'agente per ottenere risultati migliori
- › Testare con molti esempi prima del rilascio per trovare i punti deboli

Cosa "vede" l'agente mentre lavora — e perché conta più delle istruzioni iniziali

Quando un agente AI lavora su un compito, non si limita a seguire le istruzioni iniziali: legge e interpreta continuamente tutto ciò che è presente nella sua "memoria di lavoro" — le istruzioni ricevute, i risultati degli strumenti usati, la storia della conversazione, lo stato attuale del compito. Questa memoria ha però un **limite fisso di spazio**. Scegliere bene cosa mettere in quello spazio — e cosa escludere — è diventata una delle competenze tecniche più importanti per chi costruisce agenti AI. Questo è il cuore dell'ingegneria del contesto.

IL CAMBIO DI PROSPETTIVA

Non le parole giuste, ma le informazioni giuste

- › La vecchia pratica cercava la formulazione perfetta delle istruzioni iniziali; quella nuova si chiede: **quali informazioni deve avere l'agente in ogni momento?**
- › Troppo poco contesto e l'agente lavora al buio; troppo e si perde tra informazioni irrilevanti che degradano la qualità delle risposte
- › Obiettivo: trovare **il minimo indispensabile di informazioni di alta qualità** che aumenta al massimo la probabilità del risultato voluto

TECNICA PRATICA

Recupero delle informazioni solo quando servono

- › Non caricare tutte le informazioni disponibili all'inizio: l'agente le cerca e le carica solo nel momento in cui gli servono davvero
- › Come un professionista esperto che non porta tutti i suoi archivi a ogni riunione — prende solo quello che serve per quella sessione
- › Questo mantiene la memoria di lavoro libera e focalizzata sul compito in corso

TECNICA PRATICA

Compressione della storia

- › Per compiti lunghi, la storia della conversazione occupa spazio prezioso nella memoria dell'agente
- › Si comprime periodicamente, tenendo solo i fatti rilevanti per i passi successivi e scartando il resto
- › Fondamentale per agenti che lavorano su ore o su più sessioni

TECNICA PRATICA

Strumenti con output compatti

- › Ogni strumento usato dall'agente produce risultati che entrano nella memoria — tenerli concisi e strutturati riduce il "rumore"
- › Uno strumento che restituisce solo le informazioni necessarie al passo successivo e più efficace di uno che restituisce tutto
- › Una buona descrizione dello strumento evita ambiguità e usi sbagliati

PROSPETTIVA FUTURA

Vale anche con modelli più capaci

- › I modelli AI migliorano continuamente, ma il limite di spazio nella memoria di lavoro rimane un **vincolo strutturale**
- › Gestire bene il contesto sarà una competenza chiave per anni, indipendentemente dai progressi tecnologici
- › Modelli più potenti richiedono meno istruzioni dettagliate, ma la qualità del contesto rimane determinante

Come si misura se un agente funziona bene — e i 5 insegnamenti chiave

Valutare un agente AI è fondamentalmente diverso dal valutare un normale sistema software. Un agente non dà una risposta singola: compie una serie di azioni concatenate, usa strumenti, modifica lo stato del sistema e si adatta ai risultati intermedi. Per questo, i metodi di test tradizionali non bastano. Anthropic ha sviluppato un approccio a più livelli: si testa prima ogni singola azione, poi le sequenze di azioni, infine il compito completo dall'inizio alla fine.

FONTE: ANTHROPIC — VALUTARE GLI AGENTI AI

Tre livelli di test per agenti complessi

- › **Livello 1 — Componente singolo:** si verifica che ogni singola azione o strumento funzioni correttamente in isolamento, come un test unitario nel software tradizionale
- › **Livello 2 — Sequenza di azioni:** si verifica che una serie di passi collegati produca il risultato atteso, identificando dove si rompono le catene logiche
- › **Livello 3 — Compito completo:** si assegna all'agente un obiettivo reale e si valuta l'intero percorso dall'inizio alla fine con criteri di giudizio automatici
- › Senza questi test, i problemi emergono solo in produzione — dove correggerne uno spesso ne crea altri a cascata
- › Scegliere uno strumento di test rapidamente e investire il tempo sui casi di prova concreti, non sulla ricerca dello strumento perfetto

Componente → Sequenza → Compito completo

SINTESI — 5 FONTI, 5 INSEGNAMENTI



BCG

Il valore reale si ottiene **ripensando i processi lavorativi** — non automatizzando singoli compiti isolati.



DELOITTE

I sistemi di controllo vanno costruiti prima di espandere: governance, ruoli chiari e processi di supervisione.



ANTHROPIC — COSTRUZIONE

Semplicità e componenti piccoli battono i sistemi complessi — testare sempre la soluzione più semplice prima.



ANTHROPIC — CONTESTO

La **memoria di lavoro dell'agente è limitata**: scegliere con cura quali informazioni includervi è decisivo per la qualità.



ANTHROPIC — VALUTAZIONE

Un agente va testato su **più livelli**: singola azione, sequenza, compito completo — non basta verificare la risposta finale.